

Boyer–Moore Algorithmus

1 Grundidee

Der **Boyer–Moore** Algorithmus sucht ein **Pattern** P in einem **Text** T, indem er Vergleiche **von rechts nach links** im Pattern macht und bei einem Mismatch das Pattern **weit nach rechts verschiebt**.

Kernideen (Heuristiken):

- **Bad Character Rule** (schlechtes Zeichen)
- **Good Suffix Rule** (gutes Suffix)

→ In der Praxis oft sehr schnell, besonders bei großen Alphabeten und langen Patterns.

2 Voraussetzungen

- Text T und Pattern P sind Strings
 - Vorverarbeitung des Patterns (Tabellen für Verschiebungen)
-

3 Laufzeiten & Eigenschaften

| Eigenschaft | Wert | |-----|-----| | Best / typische Praxis | sehr schnell (sublinear möglich) | | Worst Case | $O(n \cdot m)$ (ohne Good-Suffix) | | Speicherbedarf | $O(|\Sigma| + m)$ | | Backtracking im Text | nein | | Anwendungsfall | String-Suche |

Hinweis: Mit beiden Heuristiken ist die Worst-Case-Garantie besser, aber die Implementierung wird deutlich komplexer. In Prüfungen wird oft die **Bad Character Rule** fokussiert.

4 Bad Character Rule (Prüfungsfokus)

Idee

Wenn ein Mismatch passiert (Textzeichen passt nicht zum Patternzeichen), kann das Pattern so verschoben werden, dass:

- das mismatching Zeichen im Pattern **unter seiner letzten Vorkommen-Position** liegt
- oder, falls es nicht vorkommt, das Pattern komplett darüber hinweg springt

Dazu wird eine Tabelle `last[char]` berechnet:

- `last[c]` = letzter Index von Zeichen c im Pattern (oder -1)
-

5 Schritt-für-Schritt-Beispiel (Bad Character)

Text:

HERE IS A SIMPLE EXAMPLE

Pattern:

EXAMPLE

Vergleich startet am Pattern-Ende (rechts). Bei Mismatch wird anhand von `last[text_char]` die Verschiebung bestimmt.

6 Good Suffix Rule (kurz, der Vollständigkeit halber)

Wenn ein Suffix im Pattern bereits gematcht hat und dann ein Mismatch kommt, verschiebt man das Pattern so, dass:

- das gematchte Suffix erneut passend ausgerichtet wird
- oder ein passender Prefix genutzt wird

→ Diese Regel macht Boyer–Moore noch schneller, ist aber komplexer.

7 Besonderheiten / Prüfungsrelevante Hinweise

- Boyer–Moore vergleicht **von rechts nach links**
 - Typische Prüfungsfrage:
 - *Wie wird die Verschiebung bei Bad Character berechnet?*
 - Häufig reicht eine Implementierung der Bad-Character-Heuristik
-

8 Vor- und Nachteile

Vorteile

- in der Praxis extrem schnell

- wenige Vergleiche (sublinear möglich)
- gut bei großem Alphabet (ASCII/Unicode)

Nachteile

- komplexer als KMP
- Worst Case kann ohne Good-Suffix schlecht sein



Merksatz für die Prüfung

Boyer–Moore sucht von rechts nach links und verschiebt das Pattern mit Bad-Character- und Good-Suffix-Regeln weit nach rechts.



Python-Implementierung (Bad Character Heuristik)

```
In [1]: def build_last(pattern):
    last = {}
    for i, ch in enumerate(pattern):
        last[ch] = i
    return last

def boyer_moore_search(text, pattern):
    if not pattern:
        return []

    last = build_last(pattern)
    n, m = len(text), len(pattern)
    result = []

    i = 0 # Startindex im Text für das aktuelle Pattern-Fenster
    while i <= n - m:
        j = m - 1 # Vergleich startet rechts im Pattern

        while j >= 0 and pattern[j] == text[i + j]:
            j -= 1

        if j < 0:
            result.append(i)
            # Verschiebe um 1 oder um m (hier: 1, um weitere Matches zu finden)
            i += 1
        else:
            bad_char = text[i + j]
            shift = j - last.get(bad_char, -1)
            i += max(1, shift)

    return result
```

```
# Beispiel
text = "HERE IS A SIMPLE EXAMPLE"
pattern = "EXAMPLE"
print(boyer_moore_search(text, pattern)) # [17]
```

[17]